
## WGS 데이터로부터.

| location | REF | Sample 1 | Sample 2 | Sample 3 | Sample 4 | Sample 5 | Sample 6 |
|----------|-----|----------|----------|----------|----------|----------|----------|
| 1        | Α   | Α        | Т        | Α        | Т        | т        | Α        |
| 2        | т   | G        | G        | Т        | G        | Т        | Т        |
| 3        | С   | С        | С        | С        | С        | С        | G        |
| 4        | G   | G        | G        | G        | G        | G        | G        |
| 5        | Α   | С        | Α        | С        | Α        | Α        | Α        |
| 6        | Α   | С        | С        | Α        | Α        | Α        | Α        |



컴퓨터가 데이터를 통해 **스스로 패턴을 학습**하고, 새로운 데이터에 대해 **예측하거나 분류**하는 알고리즘을 만들 수 있을까

# 변이정보로부터

| location | REF | Sample 1 | Sample 2 | Sample 3 | Sample 4 | Sample 5 | Sample 6 |
|----------|-----|----------|----------|----------|----------|----------|----------|
| 1        | Α   | Α        | Т        | Α        | Т        | т        | Α        |
| 2        | т   | G        | G        | Т        | G        | т        | Т        |
| 3        | С   | С        | С        | С        | С        | С        | G        |
| 4        | G   | G        | G        | G        | G        | G        | G        |
| 5        | Α   | С        | Α        | С        | Α        | Α        | Α        |
| 6        | Α   | С        | С        | Α        | Α        | Α        | Α        |








# Supervised vs Unsupervised

#### Supervised Learning (지도학습)

입력 x와 레이블 Y(정답)가 쌍(pair)으로 주어질 때, 학습을 통해 새로운 입력에 대한 NEW Y(예측값)를 생성



# 기계학습의 기본 틀(Supervised)

1. 데이터 준비

학습데이터

정답 레이블 2. 전처리

전처리 된 학습데이터 정답 레이블

3. 학습모델 구축

전처리 된 학습데이터 정답 레이블 (y)

$$y = f(x)$$

4. 모델 평가

학습에 사용하지 않은 데이터 예측 레이블 (y')

$$y' = f(x')$$
$$|\tilde{y} - y'|$$

### 1. 데이터 준비

### 1. 데이터 준비(학습데이터)

| location | Sample 1 | Sample 2 | Sample 3 | Sample 4 | Sample 5 | Sample 6 | Sample 7 | Sample 8 |
|----------|----------|----------|----------|----------|----------|----------|----------|----------|
| 1        | 0.815    | 0.278    | 0.957    | 0.792    | 0.679    | 0.706    | 0.695    | 0.766    |
| 2        | 0.906    | 0.547    | 0.485    | 0.959    | 0.758    | 0.032    | 0.317    | 0.795    |
| 3        | 0.127    | 0.958    | 0.800    | 0.656    | 0.743    | 0.277    | 0.950    | 0.187    |
| 4        | 0.913    | 0.965    | 0.142    | 0.036    | 0.392    | 0.046    | 0.034    | 0.490    |
| 5        | 0.632    | 0.158    | 0.422    | 0.849    | 0.655    | 0.097    | 0.439    | 0.446    |
| 6        | 0.098    | 0.971    | 0.916    | 0.934    | 0.171    | 0.823    | 0.382    | 0.646    |

| Y1 | Α   | В   | С   | Α   | Α   | С   | С   | В   |
|----|-----|-----|-----|-----|-----|-----|-----|-----|
| Y2 | 3.4 | 2.2 | 5.5 | 6.6 | 8.1 | 9.9 | 7.7 | 6.6 |

## 2. 데이터 준비

### 1. 데이터 준비

| 학습데 | 0 | 터 |
|-----|---|---|
|-----|---|---|

| location | Sample 1 | Sample 2 | Sample 3 | Sample 4 | Sample 5 | Sample 6 | Sample 7 | Sample 8 |
|----------|----------|----------|----------|----------|----------|----------|----------|----------|
| 1        | 0.815    | 0.278    | 0.957    | 0.792    | 0.679    | 0.706    | 0.695    | 0.766    |
| 2        | 0.906    | 0.547    | 0.485    | 0.959    | 0.758    | 0.032    | 0.317    | 0.795    |
| 3        | 0.127    | 0.958    | 0.800    | 0.656    | 0.743    | 0.277    | 0.950    | 0.187    |
| 4        | 0.913    | 0.965    | 0.142    | 0.036    | 0.392    | 0.046    | 0.034    | 0.490    |
| 5        | 0.632    | 0.158    | 0.422    | 0.849    | 0.655    | 0.097    | 0.439    | 0.446    |
| 6        | 0.098    | 0.971    | 0.916    | 0.934    | 0.171    | 0.823    | 0.382    | 0.646    |
|          |          |          |          |          |          |          |          |          |
| Y1       | Α        | В        | С        | Α        | Α        | С        | С        | В        |
| Y2       | 3.4      | 2.2      | 5.5      | 6.6      | 8.1      | 9.9      | 7.7      | 6.6      |
|          |          |          |          |          |          |          |          |          |

#### 검증데이터

| location | Sample 9 | Sample 10 | Sample 11 | Sample 12 | Sample 13 |
|----------|----------|-----------|-----------|-----------|-----------|
| 1        | 0.709    | 0.119     | 0.751     | 0.547     | 0.814     |
| 2        | 0.755    | 0.498     | 0.255     | 0.139     | 0.244     |
| 3        | 0.276    | 0.960     | 0.506     | 0.149     | 0.929     |
| 4        | 0.680    | 0.340     | 0.699     | 0.258     | 0.350     |
| 5        | 0.655    | 0.585     | 0.891     | 0.841     | 0.197     |
| 6        | 0.163    | 0.224     | 0.959     | 0.254     | 0.251     |
|          |          |           |           |           |           |
| Y1       | В        | Α         | С         | В         | В         |
| Y2       | 2.4      | 4.2       | 5.1       | 7.1       | 4.2       |
|          |          |           |           |           |           |

#### 데이터가 지저분해요

| Sample 1 | Sample 2 | Sample 3 | Sample 4 | Sample 5 | Sample 6 | Sample 7 |
|----------|----------|----------|----------|----------|----------|----------|
| 0.616    | 0.917    | NaN      | 0.569    | 0.311    | 0.689    | NaN      |
| 0.473    | NaN      | NaN      | 0.469    | 0.529    | 0.748    | 0.826    |
| 0.352    | 0.757    | 0.531    | NaN      | NaN      | 0.451    | 0.538    |
| 0.831    | 0.754    | 0.779    | 0.337    | 0.602    | NaN      | 0.996    |
| 0.585    | 0.380    | 0.934    | NaN      | NaN      | NaN      | NaN      |
| 0.550    | 0.568    | NaN      | 0.794    | 0.654    | 0.913    | 0.443    |

#### 데이터가 지저분해요

| Sample 1 | Sample 2 | Sample 3 | Sample 4 | Sample 5 | Sample 6 | Sample 7 |
|----------|----------|----------|----------|----------|----------|----------|
| 0.616    | 0.917    | NaN      | 0.569    | 0.311    | 0.689    | NaN      |
| 0.473    | NaN      | NaN      | 0.469    | 0.529    | 0.748    | 0.826    |
| 0.352    | 0.757    | 0.531    | NaN      | NaN      | 0.451    | 0.538    |
| 0.831    | 0.754    | 0.779    | 0.337    | 0.602    | NaN      | 0.996    |
| 0.585    | 0.380    | 0.934    | NaN      | NaN      | NaN      | NaN      |
| 0.550    | 0.568    | NaN      | 0.794    | 0.654    | 0.913    | 0.443    |

| Sample 1 | Sample 2 | Sample 3 | Sample 4 | Sample 5 | Sample 6 | Sample 7 |  |  |
|----------|----------|----------|----------|----------|----------|----------|--|--|
| 0.616    | 0.917    | 0.620    | 0.569    | 0.311    | 0.689    | NaN      |  |  |
| 0.473    | 0.609    | 0.609    | 0.469    | 0.529    | 0.748    | 0.826    |  |  |
| 0.352    | 0.757    | 0.531    | 0.525    | 0.525    | 0.451    | 0.538    |  |  |
| 0.831    | 0.754    | 0.779    | 0.337    | 0.602    | NaN      | 0.996    |  |  |
| 삭제       |          |          |          |          |          |          |  |  |
| 0.550    | 0.568    | 0.653    | 0.794    | 0.654    | 0.913    | 0.443    |  |  |

다른 샘플들의 평균 등으로 채우거나,해당 Feature 를 삭제

### 샘플 마다 실험 환경이 달랐어요

| Sample 1 | Sample 2 | Sample 3 | Sample 4 | Sample 5 | Sample 6 | Sample 7 |
|----------|----------|----------|----------|----------|----------|----------|
| 2        |          | 4        |          | 12       |          |          |
| 2        |          | 4        |          | 12       |          |          |
| 4        |          | 8        |          | 16       |          |          |
| 4        |          | 8        |          | 16       |          |          |
| 5        |          | 10       |          | 20       |          |          |
| 1        |          | 2        |          | 4        |          |          |

### 샘플 마다 실험 환경이 달랐어요

| Sample 1 | Sample 2 | Sample 3 | Sample 4 | Sample 5 | Sample 6 | Sample 7 |
|----------|----------|----------|----------|----------|----------|----------|
| 2        |          | 4        |          | 12       |          |          |
| 2        |          | 4        |          | 12       |          | •••      |
| 4        |          | 8        |          | 16       |          | •••      |
| 4        |          | 8        |          | 16       |          | •••      |
| 5        |          | 10       |          | 20       |          |          |
| 1        |          | 2        |          | 4        |          |          |

| Sample 1 | Sample 2 | Sample 3 | Sample 4 | Sample 5 | Sample 6 | Sample 7 |
|----------|----------|----------|----------|----------|----------|----------|
| 2        |          | 2        |          | 2        |          |          |
| 2        |          | 2        |          | 2        |          |          |
| 4        |          | 4        |          | 4        |          |          |
| 4        |          | 4        |          | 4        |          |          |
| 5        |          | 5        |          | 5        |          |          |
| 1        |          | 1        |          | 1        |          |          |

실험이 잘못된 게 아니라면 정규화 작업을 진행!! 예) Z-score 변환

$$z_i = rac{x_i - \mu}{\sigma}$$

### 데이터가 너무 많아요

| Sample 1 | Sample 2 | Sample 3 | Sample 4 | Sample 5 | Sample 6 | Sample 7 |
|----------|----------|----------|----------|----------|----------|----------|
| 0.107    | 0.084    | 0.182    | 0.550    | 0.402    | 0.417    | 0.338    |
| 0.962    | 0.400    | 0.264    | 0.145    | 0.076    | 0.050    | 0.900    |
| :        | ŧ        | ÷        | ŧ        | ÷        | ŧ        | :        |
| :        | ŧ        | ÷        | ŧ        | ÷        | ŧ        | :        |
| 0.817    | 0.431    | 0.869    | 0.351    | 0.184    | 0.491    | 0.780    |
| 0.869    | 0.911    | 0.580    | 0.513    | 0.240    | 0.489    | 0.390    |

#### 데이터가 너무 많아요


| Sample 1 | Sample 2 | Sample 3 | Sample 4 | Sample 5 | Sample 6 | Sample 7 |
|----------|----------|----------|----------|----------|----------|----------|
| 0.107    | 0.084    | 0.182    | 0.550    | 0.402    | 0.417    | 0.338    |
| 0.962    | 0.400    | 0.264    | 0.145    | 0.076    | 0.050    | 0.900    |
| ŧ        | ÷        | :        | :        | :        | ÷        | ÷        |
| ŧ        | ÷        | :        | :        | :        | ÷        | ÷        |
| 0.817    | 0.431    | 0.869    | 0.351    | 0.184    | 0.491    | 0.780    |
| 0.869    | 0.911    | 0.580    | 0.513    | 0.240    | 0.489    | 0.390    |

| Sample 1 | Sample 2 | Sample 3 | Sample 4 | Sample 5 | Sample 6 | Sample 7 |
|----------|----------|----------|----------|----------|----------|----------|
| 0.107    | 0.084    | 0.182    | 0.550    | 0.402    | 0.417    | 0.338    |
| 0.962    | 0.400    | 0.264    | 0.145    | 0.076    | 0.050    | 0.900    |
| 0.869    | 0.911    | 0.580    | 0.513    | 0.240    | 0.489    | 0.390    |

| Sample 1 | Sample 2 | Sample 3 | Sample 4 | Sample 5 | Sample 6 | Sample 7 |
|----------|----------|----------|----------|----------|----------|----------|
| 0.762    | 0.598    | 0.298    | 0.279    | 0.628    | 0.165    | 0.932    |
| 0.176    | 0.766    | 0.920    | 0.555    | 0.612    | 0.768    | 0.126    |
| 0.996    | 0.597    | 0.625    | 0.521    | 0.352    | 0.186    | 0.544    |

의미 있는 Feature 들만 선택하거나, 차원 축소의 방법을 사용!


### 의미 있는 Feature 데이터란?



모든 샘플에서 비슷한 값이면 Filtering: 예) 표준편차가 작은 Feature 는 학습에서 제외

### 의미 있는 Feature 데이터란?


② 목적에 맞게 데이터값의 분포가 다른 Feature



차이가 확연한 Feature 를 선택 예) T-test 유의성 검정 등 (Y label 을 선택하는데 효력이 없지 않을까?)


### 차원 축소 데이터란?


N 차원 데이터를 N 보다 작은 데이터로 표현( 정보는 최대한 간직하면서!)




### 차원 축소 데이터란?

Principle component analysis (PCA)






#### 선형 모델 (Linear regression)




$$Y' \sim a'x + b'$$

선형모델에서 최소화해야할 값: 
$$ext{RMSE} = \sqrt{rac{1}{n}\sum_{i=1}^n(y_i-\hat{y}_i)^2}$$

#### 분류 모델 (Classification)




#### 분류 모델 (SVM Classification)




#### 분류 모델 (Linear Discriminant Analysis)





#### 분류 모델 (Tree Classification)

Decision Tree (No Bootstrap)



# 4. 모델평가는 어떻게

| Υ      | 예측      | Y-예측    |
|--------|---------|---------|
| 0      | 1.9016  | -1.9016 |
| 0.3448 | 2.3487  | -2.0039 |
| 0.6897 | 1.7574  | -1.0678 |
| 1.0345 | -0.0143 | 1.0488  |
| 1.3793 | -1.0298 | 2.4091  |
| 1.7241 | 5.9303  | -4.2062 |
| 2.069  | 6.1714  | -4.1024 |
| 2.4138 | 3.9971  | -1.5833 |
| 2.7586 | 3.4109  | -0.6523 |
| 3.1034 | -4.6207 | 7.7241  |
| 3.4483 | 2.0249  | 1.4233  |
| 3.7931 | 7.3159  | -3.5228 |

|    |     | 실제  |     |     |     |     |  |  |  |
|----|-----|-----|-----|-----|-----|-----|--|--|--|
|    |     | AFR | EUR | EAS | SAS | AMR |  |  |  |
|    | AFR | 178 | 0   | 0   | 0   | 1   |  |  |  |
|    | EUR | 0   | 127 | 0   | 2   | 22  |  |  |  |
| 예측 | EAS | 0   | 0   | 117 | 0   | 0   |  |  |  |
|    | SAS | 0   | 0   | 0   | 118 | 0   |  |  |  |
|    | AMR | 1   | 0   | 0   | 0   | 75  |  |  |  |

선형 모델은 RMSE, 분류 모델은 Accuracy

## SNV를 수치 값으로

#### **SNV**

| location | REF | Sample 1 | Sample 2 | Sample 3 | Sample 4 | Sample 5 | Sample 6 |
|----------|-----|----------|----------|----------|----------|----------|----------|
| 1        | Α   | Α        | Т        | Α        | Т        | Т        | Α        |
| 2        | т   | G        | G        | Т        | G        | т        | Т        |
| 3        | С   | с        | С        | С        | С        | С        | G        |
| 4        | G   | G        | G        | G        | G        | G        | G        |
| 5        | A   | С        | Α        | С        | Α        | Α        | Α        |
| 6        | Α   | С        | С        | Α        | Α        | Α        | Α        |

#### **Data matrix**

| location | REF | Sample 1 | Sample 2 | Sample 3 | Sample 4 | Sample 5 | Sample 6 |
|----------|-----|----------|----------|----------|----------|----------|----------|
| 1        | 0   | 0        | 1        | 0        | 1        | 2        | 0        |
| 2        | 0   | 1        | 2        | 0        | 1        | 0        | 0        |
| 3        | 0   | 0        | 0        | 0        | 0        | 0        | 1        |
| 4        | 0   | 0        | 0        | 0        | 0        | 0        | 0        |
| 5        | 0   | 1        | 0        | 1        | 0        | 0        | 0        |
| 6        | 0   | 1        | 2        | 0        | 0        | 0        | 0        |

참조 유전체서열(REF)과 다르면 1 같으면 0

그렇다면 2가 의미하는 것은?

# 변이정보로부터

| location | REF | Sample 1 | Sample 2 | Sample 3 | Sample 4 | Sample 5 | Sample 6 |
|----------|-----|----------|----------|----------|----------|----------|----------|
| 1        | 0   | 0        | 1        | 0        | 1        | 2        | 0        |
| 2        | 0   | 1        | 2        | 0        | 1        | 0        | 0        |
| 3        | 0   | 0        | 0        | 0        | 0        | 0        | 1        |
| 4        | 0   | 0        | 0        | 0        | 0        | 0        | 0        |
| 5        | 0   | 1        | 0        | 1        | 0        | 0        | 0        |
| 6        | 0   | 1        | 2        | 0        | 0        | 0        | 0        |







### Classification

실습